Befor / After Winsorization to solve the fat-tail problem

数据清洗 → 极端值处理.

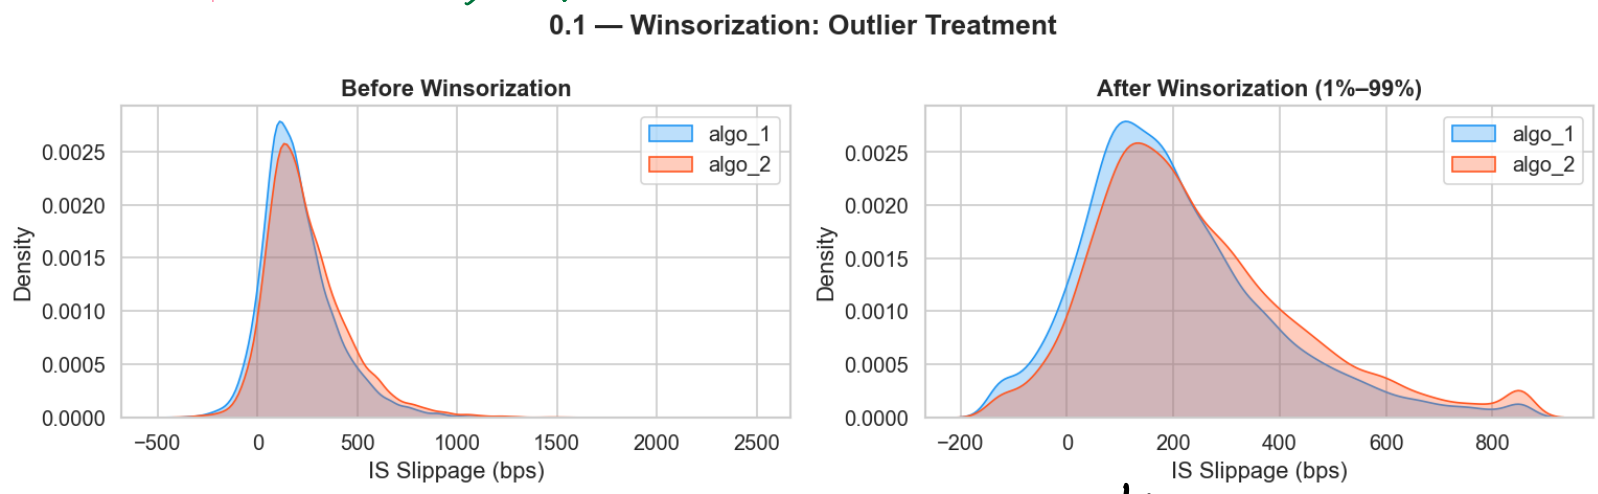

obvious right-tilted problem

higher variance, wider distributed

data structure (Raw scale)

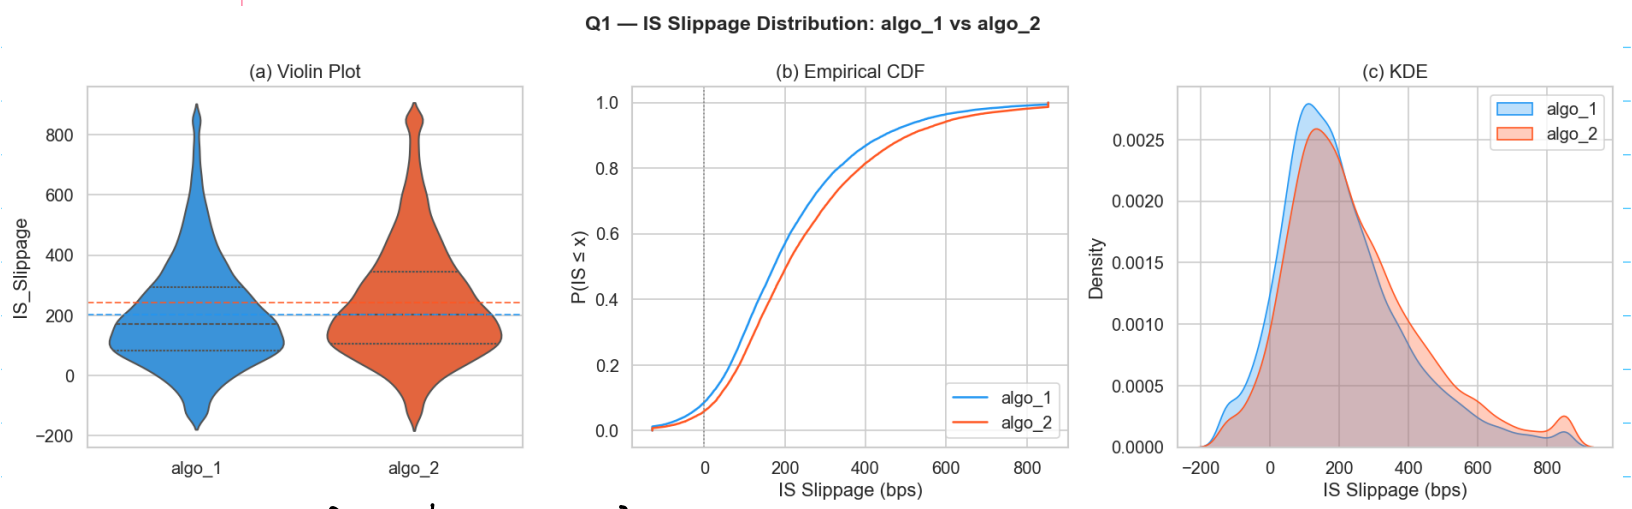

algo_2 (median) > algo_1 (median)

algo_2 上半部分更宽.

下尾形状相似

algo_1 全程在 algo_2 左侧 ⇒ algo_1 在每个分位点都比 algo_2 便宜

⇓

Q1中 algo_2 更贵.

⇓

右尾重叠明显

Q2 — Cumulative Contribution to Notional-Weighted IS (名义加权均值)

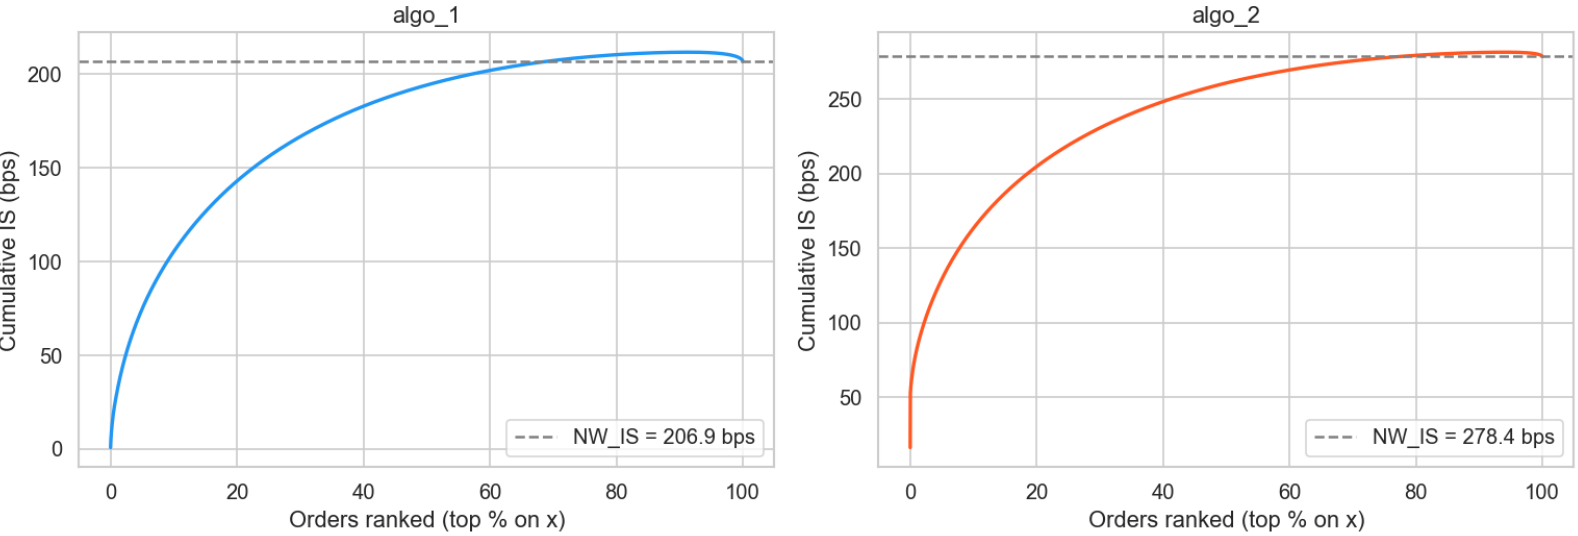

1. 两条曲线都"凹型"(gradient逐↑, ↓)
2. 前20%都贡献了大单
3. algo_2曲线上升更陡 → 大单成本占比更高

algo_2问题是：大单多会把IS拉高.

Q3 — Feature Distributions by Algo (top: raw, bottom: log-scale / violin)

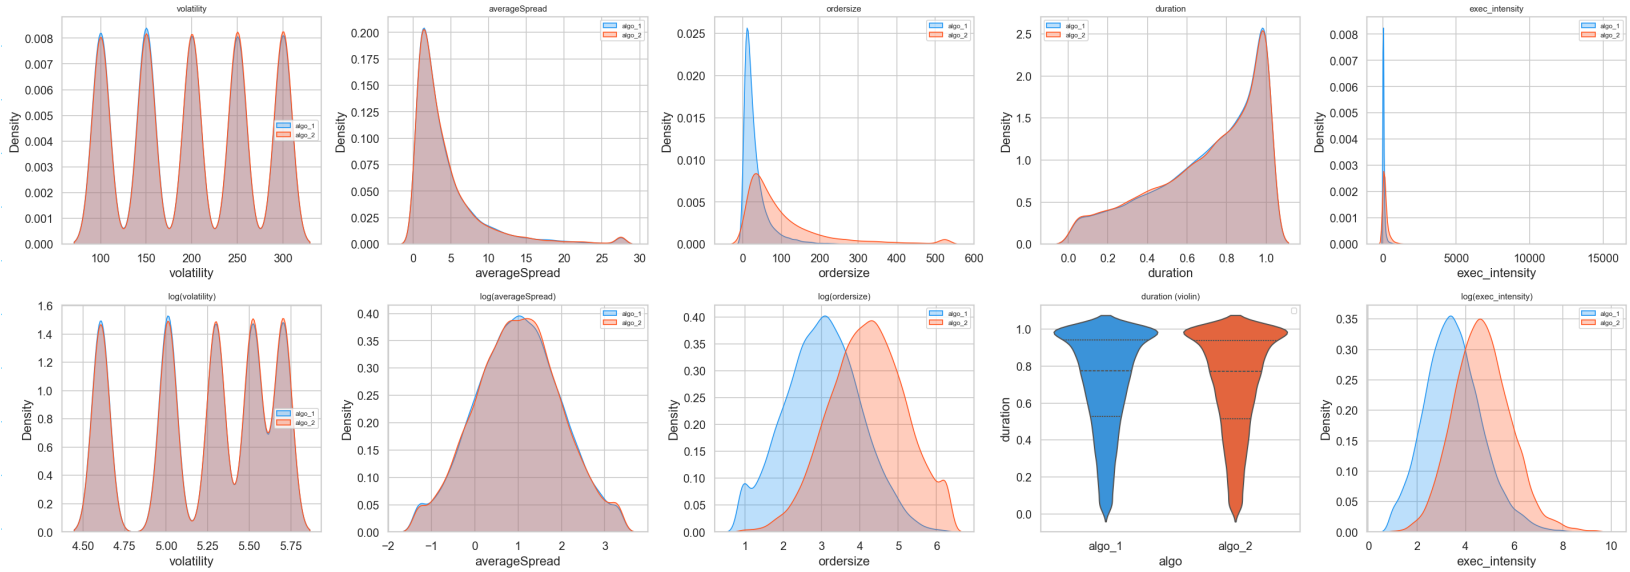

↓ 基本无偏差

↓ 基本无偏差

↓ 大偏差, algo_2明显派了更多的大单 ⇒ 路由偏差

↓ 基本无差

↓ algo_2整体右移 ⇒ algo_2执行价格高

上组图为 raw scale
下组图为 log-scale.

(路由偏差：
- 交易规模偏差：order size (订单大小)
- 流动性偏差：spread (价差)

algo 更贵的原因 { ordersize 大 / exec_intensity 高 } 不能直接比较

IS 与几个变量的相关性.

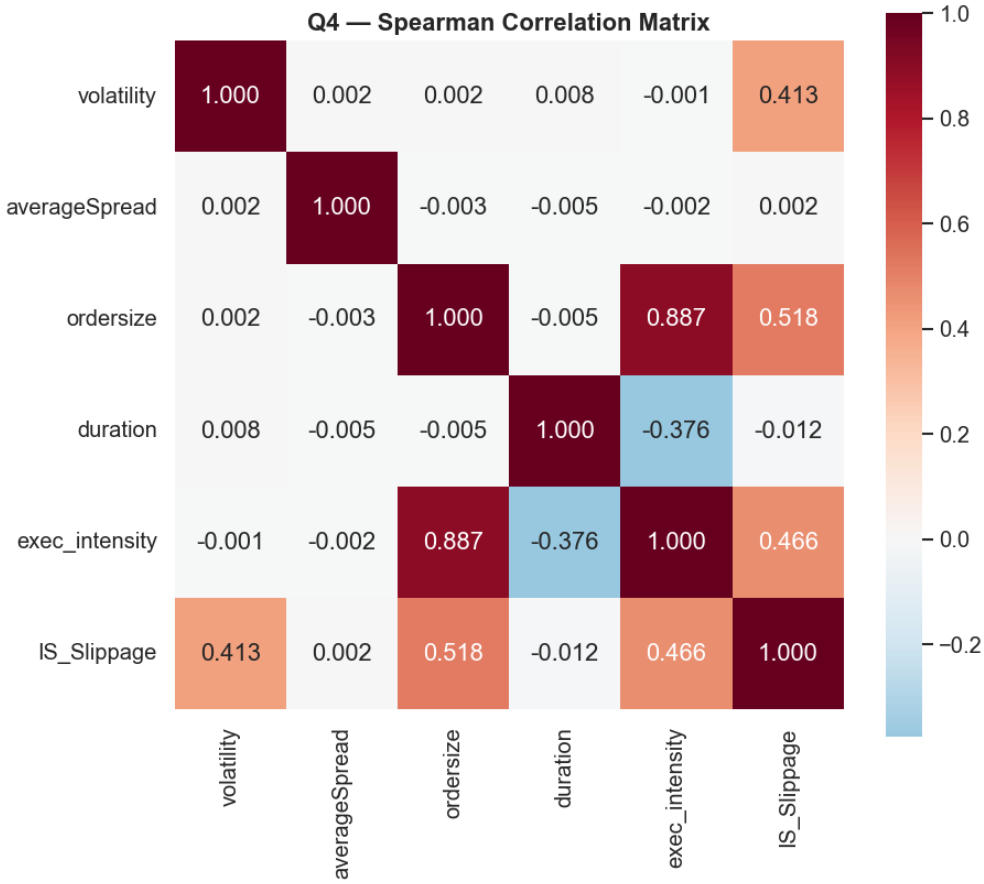

volidility
⇒ ordersize
exec_intensity

strong correlation

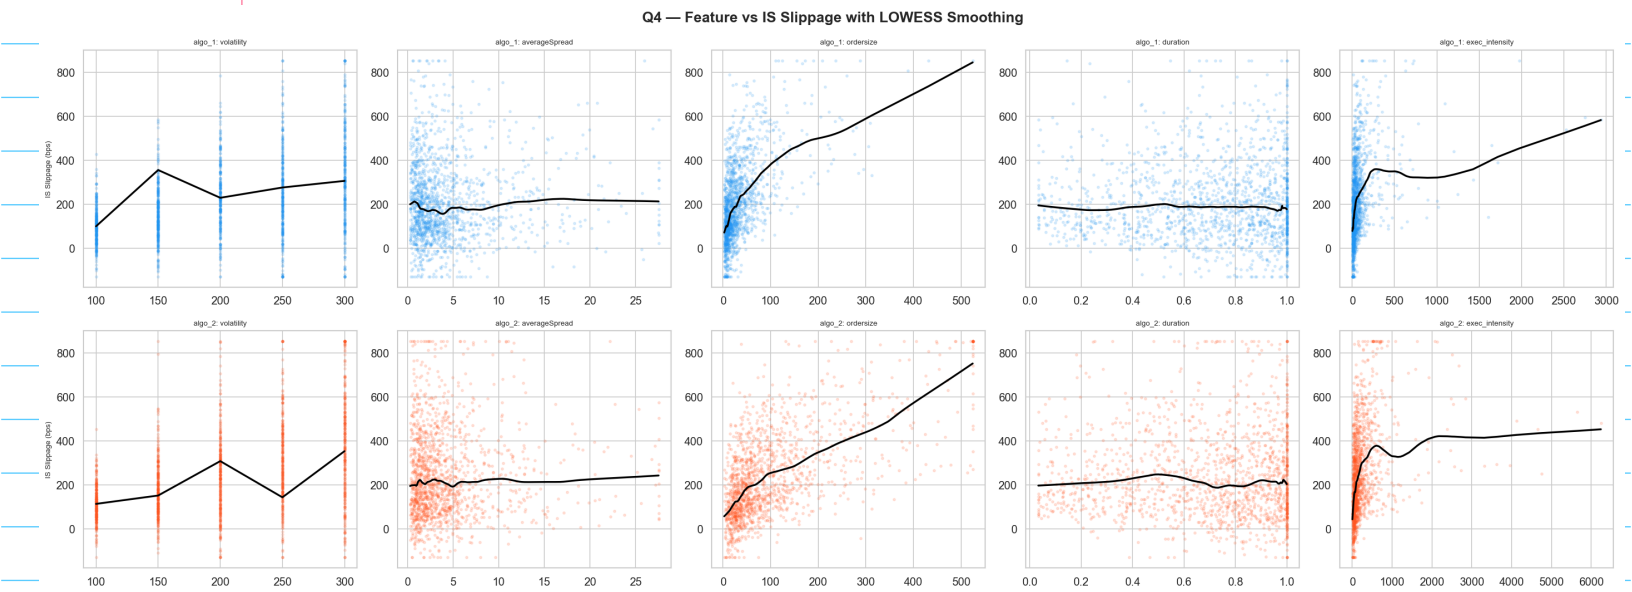

非单调，log 后无法完全线性化 ⇒ log( )

几乎直线 log( )

强单调上升 典型平方根关系 sqrt( )

基本平，原始.

{ 低强度区：快速上升 / 高强度：{ 1. 上升 2. 平缓 } sqrt( )

OLS 残差分析

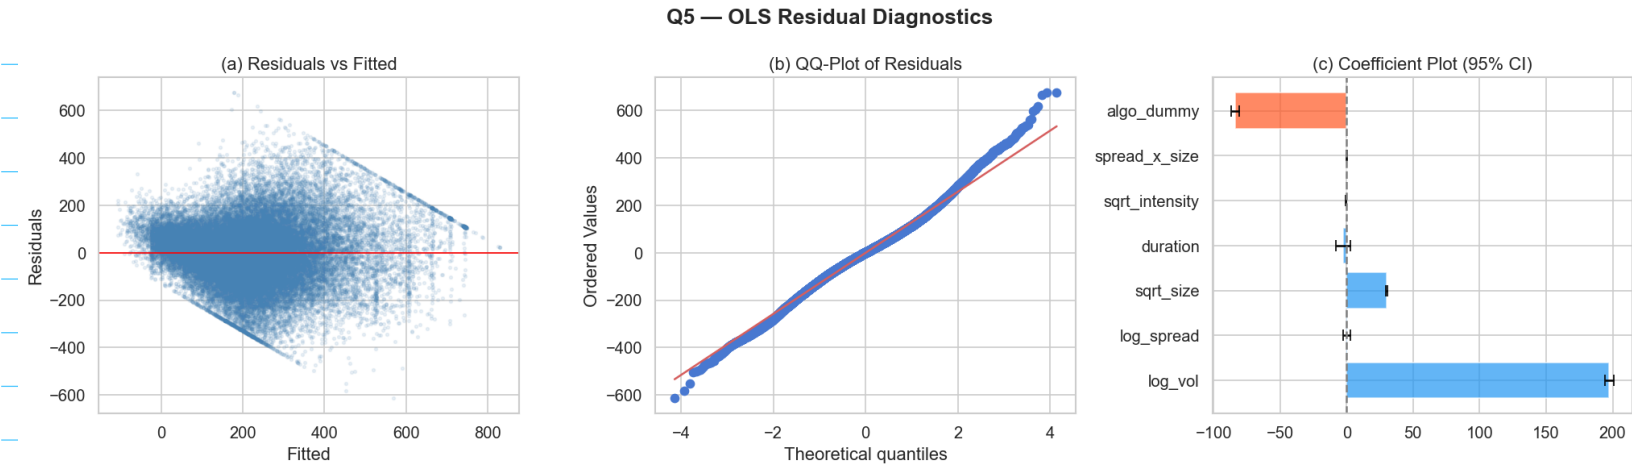

⇓

噪声入水 (Fitted Value 拟合值↑ Residual 越大)

异方差显著 (随X变化, Var(ε)变化)

⇓

中间段贴合正态分布

尾部翘起, 厚尾问题

⇓

algo_dummy 负 ⇒ algo_2 便宜

algo_dummy 定义:

在其它变量都不变情况下, 将订单从 Algo_1 到 Algo_2, IS 平均变化是为 -83.6 bps

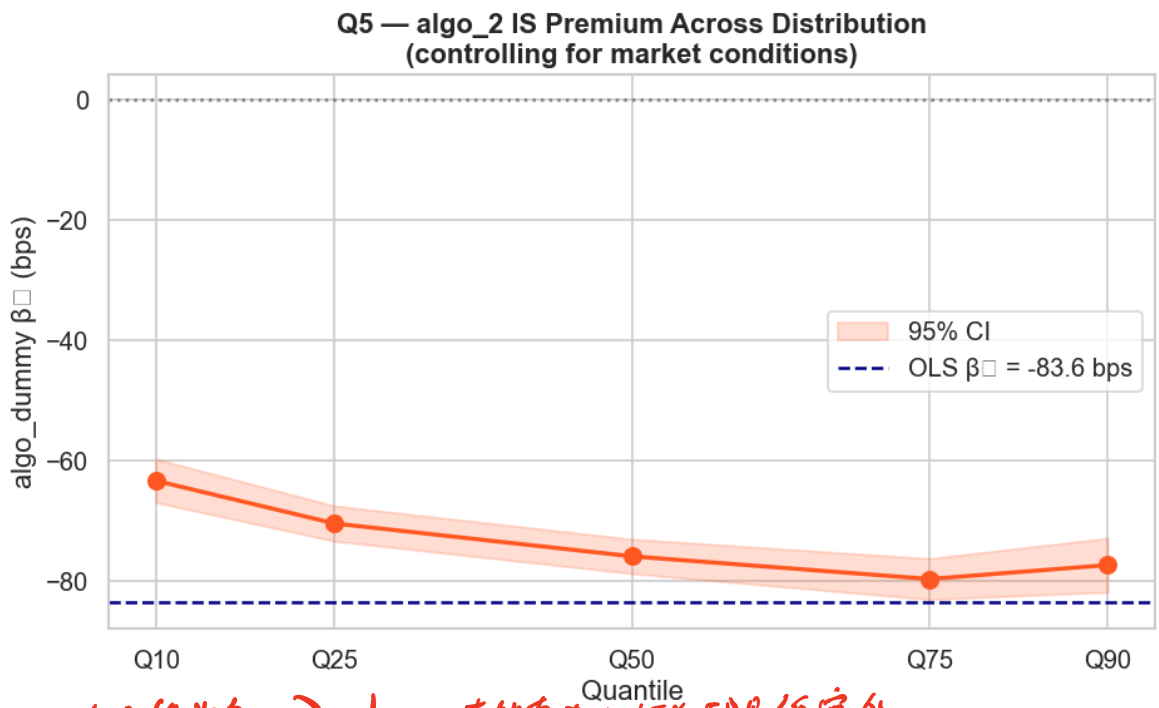

全分段为负 ⇒ algo_2 在所有类的订单都是便宜的

相比于 OLS ⇒ Huber 会给保守估计来处理异常问题

⇒ algo 2 优势全分布均匀分布

成交率 vs. IS散点

Q6 — Partial Fill Survivorship Bias (部分成交生存偏差)

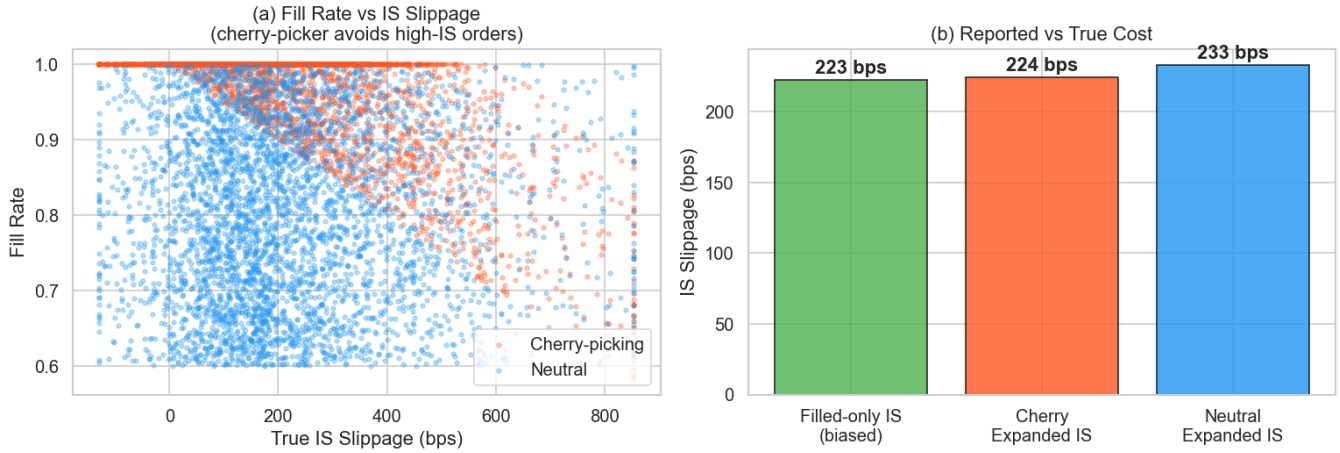

Cherry-Picker：为了帐面好看，故意只做简单活儿
去有IS低的时候才去买

⇒ 可以看到 Cherry-Picker 基本在 True IS 低且
Neutral 人少的时候下场

⇓

部分成交偏差存在但幅度有限(10bps)

Q7 — LightGBM + SHAP Analysis

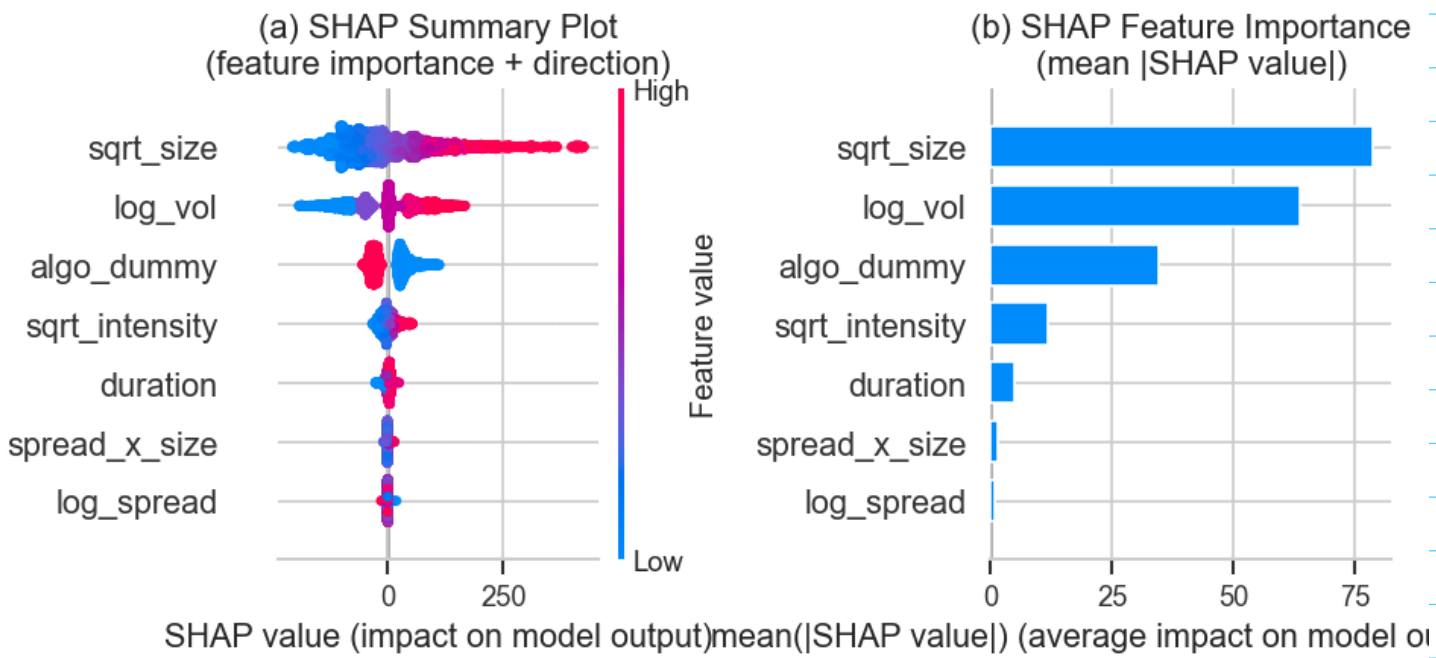

重要性 : size > volitility > algo_dummy > intensity

Summary plot:

sqrt_size: 红点(大单)集中在右侧 ⇒ 大单推高IS

log_vol: 波动高 集中在右侧 ⇒ 波动推高IS

algo_dummy: 策略Algo_2 降低IS